

考虑异质用户的高速公路换电站运营 MPC-RL 分层协同优化

2026 年 8 月 10 日

摘 要

在此填写摘要内容

目录

1	Introduction	4
2	MPC Formulation	6
2.1	滚动优化机制	6
2.2	变量列表	7
2.3	SOC-wise expanded network	7
2.4	Mathematical model	9
2.4.1	Reservation service representation	11
2.4.2	Objective function	12
2.4.3	Constraints	12
3	RL Formulation	14
3.1	Markov decision process	14
3.2	RL algorithm	15
4	Experiments	16
5	Conclusion	16

基于深度强化学习的考虑异质用户的高速公路换电站运营优化

1 Introduction

随着电动汽车在高速公路中长距离出行场景中的普及，沿线换电站的运营能力逐渐成为影响用户出行可靠性与系统运行效率的关键因素。相比传统充电方式，换电模式能够显著缩短车辆补能时间，但其运营过程同时受到用户到达需求、电池库存状态、站内充电过程以及电价变化等因素影响。【特别是在高速公路场景中，用户行驶路径具有明显的连续性，不同车辆的初始 SOC 存在差异，导致其可达站点、可行换电路径以及对站内满电电池的使用情况均不相同。】(这句话写得不好，没有讲清楚高速场景下的用户换电特点，只是简单的讲了连续性，但是没有讲清楚连续性是什么) 因此，高速公路换电站运营本质上是一个具有时空耦合、库存动态演化和不确定需求特征的序贯决策问题。

在实际运营中，系统中存在两类异质用户：预约用户和随机到达用户。预约用户通常提前提交出发时间、行程起点和终点，以及初始 SOC 信息给运营者，运营者告知用户换电站点的合理分配方案，并规划站内电池充电计划以提高服务确定性；随机用户的到达时间和到达 SOC 则具有更强的不确定性，其可服务量取决于现场站点在服务预约到达用户后仍可用的满电电池数量。此外，考虑到在现实中用户提交预约信息的时间和实际到达的时间存在差异，以及系统中存在由随机用户到达带来的不确定性。因此，还需要根据用户实际到达情况 (包括到达时间和到达 SOC)，为预约用户实时动态规划合理的换电方案。并且，由于分时电价机制的存在，站内电池充电成本会随时间变化，进一步增加了运营决策的复杂性。因此，如何在预约用户服务保障、随机用户灵活接纳以及电池充电调度之间进行协调，是高速公路换电网络运营中的核心问题。

针对上述问题，本文构建 MPC-RL 分层协同优化框架。换电站的实时运营中存在两类性质不同但相互耦合的决策：一类是预约用户换电路径指派动态调整决策，即为每位预约用户相对于提交预约时的规划方案，根据实际到达情况调整其接受服务的换电站序列；另一类是充电功率决策，即不同站点的电池在不同时段的实时充电功率安排。本文采用模型预测控制 (Model Predictive Control, MPC) 在滚动预测时域内处理预约用户换电路径指派动态调整问题。(在这里需要详细讲为什么采用 MPC 来做) 充电功率决策的影响具有明显的跨时段累积性：当前充电功率不仅决定当前充电成本，还会改变未来各站点不同 SOC 电池分布、满电电池供给能力和后续用户服务水平。本文采用强化学习 (Reinforcement Learning, RL) 学习充电功率控制策略，使其能够在长期交互过程中根据需求、电价和库存状态自适应调整充电行为。如图 1 所示，RL 层输出充电功率决策并影响电池状态转移，MPC 层在给定功率策略下优化预约用户指派方案，随机用户服务量则由剩余满电电池供给确定。

进一步地，本文利用 RL critic 提供预测时域之外的长期价值信息，以缓解有限预测

时域导致的末端效应。传统 MPC 通常通过设置固定终端库存下界避免时域末端过度消耗满电电池，但该方法只能粗略限制末端满电电池数量，难以区分不同站点、不同 SOC 电池在未来需求和电价环境下的长期价值。本文在 RL 训练过程中学习状态价值函数，并在每轮 MPC 求解前计算 critic 对终端库存的梯度，将其作为不同站点、不同 SOC 电池的长期边际价值。对于由当前预约指派产生但换电时刻位于预测域之外的履约需求，本文不额外训练新的 critic 分量，而是将其直接转化为对终端库存的等效影响：未来履约需要消耗满电电池，同时会归还低 SOC 电池。由此，RL 学到的长期库存价值被转化为 MPC 目标函数中的线性终端价值项。

因此，本文提出的 MPC-RL 框架并非将两类方法简单拼接，而是基于决策属性进行分层：MPC 负责处理强约束、组合结构明显且需要可解释性的用户服务分配问题；RL 负责学习具有长期影响的充电功率策略，并通过 critic 向 MPC 提供终端库存价值信息。二者通过电池库存状态、充电功率决策、跨域预约履约需求和终端价值项相互连接，从而在保证预约用户服务质量要求和运营约束可行性的同时，使有限时域 MPC 能够近似感知预测时域之外的长期影响。

本文其余部分安排如下：第 2 节介绍 MPC 优化模型，包括时域设置、变量定义、SOC-wise expanded network 建模方法以及数学规划模型；第 3 节介绍 RL formulation，包括马尔可夫决策过程的建立和所选 RL 算法；第 4 节和第 5 节分别预留实验分析和结论部分。

MPC做指派 DRL做功率优化




图 1: MPC-RL 协同优化框架

2 MPC Formulation

2.1 滚动优化机制




图 2: Rolling Horizon

如图 2 所示，本文采用滚动时域优化思想刻画换电站运营中的动态决策过程。设当前滚动决策时刻为 t 。 H_1 表示预测周期长度。在该预测周期内，系统可获得随机到达用户的预测需求信息，包括到达站点、到达数量以及到达时的 SOC 水平；同时，RL 层给出未来 H_1 个时段内的充电功率信息，作为 MPC 库存转移中的外部参数。 H_2 表示预约周期长度：在预约模式下，若用户计划在时刻 $t + H_2$ 出发，则必须在时刻 t 之前提交预约信息。因此，在任一滚动决策时刻 t ，区间 $[t, t + H_2]$ 内出发用户的预约信息可视为已经固定，预约信息包括出发 SOC 水平以及行程起点-终点。 h 为提前通知时间，即在区间 $[t + h, t + h + 1]$ 出发的预约用户需要在时刻 t 被通知其换电站指派方案。在时刻 t 求解 MPC 时，模型并不只考虑即将通知的一个出发时段，而是在滚动预测窗口内联合优化区间 $[t + h, t + H_1]$ 出发的预约用户指派方案；求解完成后，仅执行并发布区间 $[t + h, t + h + 1]$ 出发预约用户的指派结果。进入下一时刻后，系统根据更新后的电池库存、预约信息、随机需求预测和 RL 充电功率重新构造并求解 MPC 问题。

为便于数学表达，后文将当前滚动窗口重新编号为局部时段集合 $\mathcal{T} = \{1, \dots, H\}$ ，其中 $t = 1$ 对应本轮将要发布指派的出发区间 $[t + h, t + h + 1]$ ， H_1 对应优化窗口 $[t + h, t + H_1]$ 内的最后一个预约出发时段；电池库存状态时点集合为 $\mathcal{T}^w = \{0, 1, \dots, H_1\}$ 。MPC 的服务决策指预约用户在 expanded network 上的指派变量 $y_{A,i,j}^{n,p,t}$ ；随机到达用户不作为独立服务决策变量，而是在给定站点、时段的满电电池库存扣除预约用户到达服务需求后，由剩余满电电池自动服务。对于预约用户， t 表示其出发时段，换电服务发生在其到达相应换电站的时段。本文假设站点间的旅行时间不变，因此 O-D 对 p 的用户到达节点 i 的时段为 $t + \tau_{p,i}$ 。预约用户的决策索引仍为出发时段 t ，而电池消耗和状态转移通过

$t + \tau_{p,i}$ 关联到实际到达时段。

当 $t + \tau_{p,i} \leq H_1$ 时，对应换电事件位于当前预测时域内，并显式进入电池库存转移约束；当 $t + \tau_{p,i} > H_1$ 时，若直接忽略该事件，会导致模型在预测域末端获得预约服务收益和服务率贡献，却不承担相应的未来满电电池消耗。为避免这一边界效应，本文不截断预约决策集合，也不额外引入新的跨域承诺决策变量，而是将预测域外的预约履约影响直接并入 RL 终端库存价值项。具体而言，一个预测域外的预约履约事件在未来会消耗一块满电电池，并归还一块对应 SOC 的低电量电池。本文将该未来库存影响近似折算为预测域终端的等效库存修正，即用终端状态处的库存边际价值评价“— 满电电池需求 + 低 SOC 电池归还”。在滚动进入后续时域后，这些已形成的预约承诺会以历史预约承诺 $\bar{y}_{A,i,j}^{n,p,k}$ 的形式进入库存状态转移。

2.2 变量列表

本文使用的变量如表 1 所示。该符号表仅列出 MPC 优化模型所需集合、参数和决策变量；RL formulation 中的状态、动作、奖励和算法符号将在第 3 节单独定义。

2.3 SOC-wise expanded network

高速公路换电场景中的预约用户具有明确的 OD 路径和初始 SOC。由于初始 SOC 不同，同一 OD 对上的用户可达站点集合和可行换电路径可能不同。为刻画这种 SOC 相关的路径可行性，本文在传统 expanded network 的基础上构建 SOC-wise expanded network。该建模方法针对每一个 OD 对 $p \in \mathcal{P}$ 和每一个初始 SOC 状态 $n \in \mathcal{N}$ ，分别构造一个有向网络 $\mathcal{G}^{n,p} = (\mathcal{V}^p, \mathcal{A}^{n,p})$ 。

在网络 $\mathcal{G}^{n,p}$ 中，节点集合 $\mathcal{V}^p$ 包括 OD 对 p 的起点 o^p 、终点 d^p 以及该路径上可经过的所有中间换电站 $\mathcal{S}^p$ 。弧集合 $\mathcal{A}^{n,p}$ 用于表示在初始 SOC 为 n 的条件下，用户从一个节点行驶到另一个节点并完成后续换电服务的可行连接。弧的可行性由路段能耗 $v_{i,j}^p$ 与车辆可用电量共同决定：若弧从起点 o^p 出发，则要求 $n \geq v_{o^p,j}^p$ ；若弧从某一中间换电站出发，则车辆刚完成换电并获得满电电池，因而要求 $N \geq v_{i,j}^p$ 。因此，能耗参数 $v_{i,j}^p$ 本身不需要索引初始 SOC，而初始 SOC 的影响通过网络弧集合 $\mathcal{A}^{n,p}$ 体现。

该网络建模方式具有两个作用。第一，它将用户初始 SOC 对可达站点和换电路径的影响显式嵌入网络结构，使得不可行的站点选择不会进入优化模型。第二，它使预约用户指派问题可以表示为网络流决策：预约需求 $f_A^{n,p,t}$ 从起点 o^p 进入网络，服务变量 $y_{A,i,j}^{n,p,t}$ 表示该类需求在弧 $(i,j) \in \mathcal{A}^{n,p}$ 上的服务流量。通过流平衡约束，模型可以保证被服务的预约用户沿一条可行路径从起点移动到终点，并在路径上的换电站消耗满电电池、归还低 SOC 电池。

需要注意的是，SOC-wise expanded network 主要用于刻画预约用户的可行路径和站点指派。随机用户由于在换电站现场到达，本文不再为其构造 OD 网络，也不将其服务量作为独立优化决策；其服务量由同一站点、同一时段在服务预约到达用户后的剩余

表 1: Notation table for the MPC optimization model

Notation	Description
<i>Sets and Indices</i>	
$\mathcal{P}$	Set of O-D pairs, indexed by p
$\mathcal{T}$	Set of decision periods in the predictive horizon, $\mathcal{T} := \{1, \dots, H\}$, indexed by t
$\mathcal{T}^w$	Set of battery inventory state points, $\mathcal{T}^w := \{0, 1, \dots, H\}$
$\mathcal{N}$	Set of discretized battery SOC states, $\mathcal{N} := \{0, \dots, N\}$, indexed by n, m, r
$\mathcal{S}^p$	Set of intermediate BSSs on the path of O-D pair p , indexed by i, j
$\mathcal{S}$	Set of all BSSs in the system, $\mathcal{S} := \bigcup_{p \in \mathcal{P}} \mathcal{S}^p$
$\mathcal{V}^p$	Node set consisting of origin o^p , destination d^p , and BSSs $\mathcal{S}^p$ on the path of O-D pair p
$\mathcal{A}^{n,p}$	Arc set in the SOC-wise expanded network for initial SOC state n and O-D pair p
$\mathcal{G}^{n,p}$	Directed graph for initial SOC state n and O-D pair p , $\mathcal{G}^{n,p} := (\mathcal{V}^p, \mathcal{A}^{n,p})$
<i>Parameters</i>	
h	Advance notice time for publishing reservation assignment decisions
H_1	Length of the prediction horizon for random demand information and RL charging power
H_2	Length of the reservation horizon with fixed reservation information
H	Number of locally indexed reservation departure periods optimized in the current rolling MPC window
$\tau_{p,i}$	Travel time from the origin to node i for an EV of O-D pair p ; it is independent of the departure time
$\tau_{p,\max}$	Maximum travel time of EVs for O-D pair p
$\tau_{\max}$	Maximum travel time over all O-D pairs, $\tau_{\max} := \max_{p \in \mathcal{P}} \tau_{p,\max}$
$P_{n,i,t}$	Charging increment or power applied to batteries with SOC state n at station i during period t ; it is provided by the RL layer and treated as a parameter in MPC
$e_{i,t}$	Electricity price at station i during period t
s	Fixed unit swapping service fee, independent of station and time
$v_{i,j}^p$	Energy consumption from node i to node j for an EV of O-D pair p ; it is independent of the user's initial SOC
α	Penalty cost per unit of unsatisfied reservation demand
η	Minimum reservation service rate required within the predictive horizon
β	Weight coefficient of the RL terminal inventory value in the MPC objective
$\lambda_{i,n,\ell}$	Marginal terminal value of one additional battery with SOC state n at station i at the current rolling decision epoch ℓ
$f_A^{n,p,t}$	Reservation demand volume of EVs with initial SOC state n for O-D pair p departing in period t
$f_R^{n,i,t}$	Random demand volume of EVs with returned SOC state n at station i in period t
$\bar{y}_{A,i,j}^{n,p,k}$	Historical service volume of reservation flows on arc (i, j) that departed before the current predictive horizon, $k \in \{-\tau_{p,\max}, \dots, 0\}$
$\bar{w}_{n,i,0}$	Initial number of batteries with SOC state n at station i at the beginning of the predictive horizon
$\underline{w}_{N,i}$	Minimum number of fully charged batteries retained at station i at the end of the predictive horizon
Φ_ℓ^{RL}	Linear terminal value term provided by the RL critic at the current rolling decision epoch ℓ
<i>Decision Variables and Induced Quantities</i>	
$y_{A,i,j}^{n,p,t}$	Service flow of reservation demand $f_A^{n,p,t}$ on arc $(i, j) \in \mathcal{A}^{n,p}$
$w_{n,i,t}$	Number of batteries with SOC state n at station i at inventory state point $t \in \mathcal{T}^w$
$y_R^{n,i,t}(y_A)$	Induced service volume of random demand $f_R^{n,i,t}$ after serving reservation arrivals at station i in period t

满电电池数量决定。预约用户和随机用户在电池库存层面相互耦合：两类用户服务均会消耗站内满电电池，并向站内归还不同 SOC 状态的电池。




图 3: 指派网络建模

2.4 Mathematical model

1. 决策变量从指派到调整。– 索引 k 2. 怎么衡量调整损失。

本节给出 MPC 层的数学规划模型。MPC 层的显式决策变量包括预约用户在 SOC-wise expanded network 上的服务流量 $y_{A,i,j}^{n,p,t}$ 以及各站点不同 SOC 电池库存 $w_{n,i,t}$ 。随机到达用户的服务量由同一站点、同一时段的可用满电电池数量以及预约用户实际到达换电量共同决定：在满足预约用户到达服务后，剩余满电电池用于服务随机到达用户。RL 层输出的充电功率 $P_{n,i,t}$ 在每轮 MPC 求解时作为外部给定参数进入电池状态转移和充电成本项。服务费用为固定单位服务费 s ，旅行时间为只依赖于 O-D 对和到达节点参数 $\tau_{p,i}$ 。

为刻画预约用户到达站点后的退回电池 SOC，定义辅助函数

$$\rho_{j,i}^{n,p} = \begin{cases} n - v_{j,i}^p, & j = o^p, \\ N - v_{j,i}^p, & j \in \mathcal{S}^p, \end{cases} \quad (1)$$

其中 $\rho_{j,i}^{n,p}$ 表示初始 SOC 为 n 的预约用户沿弧 (j,i) 到达站点 i 时退回电池的 SOC。第一种情况对应用户从起点携带原始电池行驶至第一个换电站，第二种情况对应用户在前一换电站换得满电电池后继续行驶。

为表示充电导致的 SOC 转移，定义

$$\chi_{m,i,t}^r = \mathbb{I}(\min\{m + P_{m,i,t}, N\} = r), \quad \forall m, r \in \mathcal{N}, i \in \mathcal{S}, t \in \mathcal{T}. \quad (2)$$

若 SOC 和功率均采用离散刻度, $\chi_{m,i,t}^r$ 表示时点 $t-1$ 处于 SOC m 的电池经过时段 t 的充电后, 在时点 t 转移至 SOC r 。

为简化表达, 定义时段 t 站点 i 需要消耗满电电池的当前预约服务量和历史预约服务量分别为

$$Q_{i,t}^{A,\text{cur}} = \sum_{p \in \mathcal{P}} \sum_{n \in \mathcal{N}} \sum_{\{j | (j,i) \in \mathcal{A}^{n,p}\}} \sum_{\{k \in \mathcal{T} | k + \tau_{p,i} = t\}} y_{A,j,i}^{n,p,k}, \quad (3)$$

$$Q_{i,t}^{A,\text{his}} = \sum_{p \in \mathcal{P}} \sum_{n \in \mathcal{N}} \sum_{\{j | (j,i) \in \mathcal{A}^{n,p}\}} \sum_{\{k \in \{-\tau_{p,\max}, \dots, 0\} | k + \tau_{p,i} = t\}} \bar{y}_{A,j,i}^{n,p,k}. \quad (4)$$

上述两个量均采用到达站点 i 的入弧流量, 电池在用户到达站点 i 并完成换电时被消耗。

令时段 t 站点 i 在服务用户前可用于换电的满电电池数量为

$$F_{i,t} = \sum_{m \in \mathcal{N}} w_{m,i,t-1} \chi_{m,i,t}^N. \quad (5)$$

则扣除当前时段实际到达的预约换电需求后, 可供随机到达用户使用的剩余满电电池数量为

$$B_{i,t}(y_A) = F_{i,t} - Q_{i,t}^{A,\text{cur}} - Q_{i,t}^{A,\text{his}}. \quad (6)$$

在物理可行约束下 $B_{i,t}(y_A) \geq 0$ 。设站点 i 、时段 t 的随机到达预测总量为

$$D_{R,i,t} = \sum_{n \in \mathcal{N}} f_R^{n,i,t}. \quad (7)$$

则随机到达用户的总服务量由剩余满电电池和随机需求共同决定:

$$Q_{i,t}^R(y_A) = \min \{D_{R,i,t}, B_{i,t}(y_A)\}. \quad (8)$$

本文假设各 SOC 类型的随机到达用户按其在随机需求中的占比分配服务量, 即

$$y_R^{n,i,t}(y_A) = \begin{cases} \frac{f_R^{n,i,t}}{D_{R,i,t}} Q_{i,t}^R(y_A), & D_{R,i,t} > 0, \\ 0, & D_{R,i,t} = 0. \end{cases} \quad (9)$$

对于由当前预测域内的预约指派产生、但换电到达时刻位于预测域之外的事件, 本文不再单独定义新的承诺变量。若预约服务流 $y_{A,j,i}^{n,p,t}$ 满足 $t + \tau_{p,i} > H$, 则该履约事件不会直接改变当前预测域内的库存变量 $w_{n,i,t}$, 因为实际换电发生在 H 之后。然而, 它会在未来站点 i 消耗满电电池, 并归还 SOC 为 $\rho_{j,i}^{n,p}$ 的电池。因此, 本文在终端价值中直接用 $-\lambda_{i,N,\ell}$ 评价未来满电电池需求, 用 $+\lambda_{i,\rho_{j,i}^{n,p},\ell}$ 评价未来低 SOC 电池归还。需要注意的是, 预测域外履约实际发生在终端时刻之后, 本文将其库存影响近似折算为终端等效库存修正, 而不再为不同域外到达时刻引入额外的时变价值系数。

有限预测时域 MPC 若仅优化预测时域内收益, 可能在时域末端过度服务当前用户, 从而留下对未来运营不利的库存结构。特别地, 当某些预约指派的实际换电时刻超过 H

时，如果只考虑终端库存而不考虑这些域外履约需求，终端状态会遗漏未来必须履约的满电电池需求。为缓解这一末端效应，本文利用 RL critic 学到的长期库存价值信息构造线性终端价值项。RL critic 学习状态价值函数

$$V_\theta(s_t) \approx \mathbb{E} \left[\sum_{h=0}^{\infty} \gamma^h r_{t+h} \mid s_t \right]. \quad (10)$$

由于 $V_\theta(s)$ 通常由深度神经网络表示，直接将其嵌入 MPC 会导致优化模型非线性且难以求解。因此，本文仅利用 critic 提取终端库存的局部边际价值。在每轮 MPC 求解前，先构造参考终端状态 $\bar{s}_{\ell+H}$ ，然后在该状态处对 $V_\theta(s)$ 关于终端库存进行一阶线性化：

$$V_\theta(s_{\ell+H}) \approx V_\theta(\bar{s}_{\ell+H}) + \sum_{i \in \mathcal{S}} \sum_{n \in \mathcal{N}} \lambda_{i,n,\ell} (w_{n,i,H} - \bar{w}_{n,i,H}), \quad (11)$$

其中

$$\lambda_{i,n,\ell} = \left. \frac{\partial V_\theta(s)}{\partial w_{n,i}} \right|_{s=\bar{s}_{\ell+H}}, \quad \forall i \in \mathcal{S}, n \in \mathcal{N}. \quad (12)$$

$\lambda_{i,n,\ell}$ 表示在当前滚动决策时刻 ℓ ，critic 在参考终端状态 $\bar{s}_{\ell+H}$ 处评估得到的库存边际价值，即站点 i 增加一块 SOC 为 n 的电池对长期价值的边际贡献。对于预测域外的预约履约需求，本文不引入新的 critic 参数，也不引入额外承诺决策变量，而是直接使用同一组库存边际价值进行终端等效评价：未来满电电池需求相当于减少满电库存，未来低 SOC 电池归还相当于增加相应 SOC 库存。因此，常数项不影响 MPC 最优解时，目标函数中保留的线性终端价值项为

$$\begin{aligned} \Phi_\ell^{\text{RL}} = & \sum_{i \in \mathcal{S}} \sum_{n \in \mathcal{N}} \lambda_{i,n,\ell} w_{n,i,H} \\ & + \sum_{p \in \mathcal{P}} \sum_{n \in \mathcal{N}} \sum_{i \in \mathcal{S}^p} \sum_{\{j|(j,i) \in \mathcal{A}^{n,p}\}} \sum_{\{t \in \mathcal{T} | t + \tau_{p,i} > H\}} \left(\lambda_{i,\rho_{j,i}^{n,p},\ell} - \lambda_{i,N,\ell} \right) y_{A,j,i}^{n,p,t}. \end{aligned} \quad (13)$$

在 MPC 求解时， $\lambda_{i,n,\ell}$ 是固定参数，故式(13) 仍然对决策变量保持线性，不会破坏原优化模型的可求解性。上述表达式的第一项评价预测域终端库存；第二项评价由当前预约指派产生、但实际换电发生在预测域之外的履约影响。若 $y_{A,j,i}^{n,p,t}$ 在预测域外到达站点 i ，则它未来需要消耗一块满电电池，带来 $-\lambda_{i,N,\ell} y_{A,j,i}^{n,p,t}$ ；同时归还一块 SOC 为 $\rho_{j,i}^{n,p}$ 的电池，带来 $+\lambda_{i,\rho_{j,i}^{n,p},\ell} y_{A,j,i}^{n,p,t}$ 。由于该履约事件实际发生在 $\ell + H$ 之后，本文将其近似为终端等效库存修正；该近似避免了为预测域外每一个到达时刻引入额外的时间索引和价值系数。

2.4.1 Reservation service representation

首先定义预测时域内被服务的预约需求总量：

$$S_A(y_A) = \sum_{t \in \mathcal{T}} \sum_{p \in \mathcal{P}} \sum_{n \in \mathcal{N}} \sum_{\{j|(o^p,j) \in \mathcal{A}^{n,p}\}} y_{A,o^p,j}^{n,p,t}. \quad (14)$$

预测时域内预约需求总量为

$$D_A = \sum_{t \in \mathcal{T}} \sum_{p \in \mathcal{P}} \sum_{n \in \mathcal{N}} f_A^{n,p,t}. \quad (15)$$

因此，未满足预约需求量可表示为 $U_A = D_A - S_A(y_A)$ ，其对应的惩罚项进入目标函数。除此之外，本文设置预约服务率约束 $S_A(y_A) \geq \eta D_A$ ，用于描述平台对已进入滚动窗口的预约用户所要求的最低服务水平。随机到达用户的服务量由式(8)–(9) 给出，即在同一站点和时段内由预约服务后的剩余满电电池自然决定，因此模型中不再需要额外设置两类用户之间的服务排序规则。

2.4.2 Objective function

目标函数为最大化预测时域内的服务收益，减去未满足预约需求惩罚和电站充电成本，并加入 RL critic 提供的线性终端价值：

$$\max \quad I - C_1 - C_2 + \beta \Phi_\ell^{\text{RL}}. \quad (16)$$

服务收益由预约用户和随机用户完成换电所产生的服务费构成。为保持与预约指派决策的时间逻辑一致，预约用户收益项以出发或指派时段 t 为决策索引；随机用户收益项则由预约服务后的剩余满电电池诱导得到：

$$\begin{aligned} I = & \sum_{t \in \mathcal{T}} \sum_{p \in \mathcal{P}} \sum_{n \in \mathcal{N}} \sum_{i \in \mathcal{S}^p} \sum_{\{j|(j,i) \in \mathcal{A}^{n,p}\}} y_{A,j,i}^{n,p,t} (N - \rho_{j,i}^{n,p}) s \\ & + \sum_{t \in \mathcal{T}} \sum_{i \in \mathcal{S}} \sum_{n \in \mathcal{N}} y_R^{n,i,t}(y_A) (N - n) s. \end{aligned} \quad (17)$$

其中 $N - \rho_{j,i}^{n,p}$ 和 $N - n$ 分别表示预约用户与随机用户在换电时获得的补能量， s 为固定单位服务费。若服务费按次收取而非按补能量收取，可将上述补能量系数并入固定服务费参数中。由于 $y_R^{n,i,t}(y_A)$ 不是独立决策变量，随机用户收益仅反映预约指派方案和库存状态所留下的可服务随机需求；跨越预测时域边界的预约指派不在当前库存转移中结算，而是通过式(13) 中的终端等效库存修正项承担未来库存影响。

未满足预约需求惩罚为

$$C_1 = \alpha \sum_{t \in \mathcal{T}} \sum_{p \in \mathcal{P}} \sum_{n \in \mathcal{N}} \left[f_A^{n,p,t} - \sum_{\{j|(o^p,j) \in \mathcal{A}^{n,p}\}} y_{A,o^p,j}^{n,p,t} \right]. \quad (18)$$

电站充电成本按照时段开始时的库存和该时段的充电功率计算：

$$C_2 = \sum_{t \in \mathcal{T}} \sum_{n \in \mathcal{N}} \sum_{i \in \mathcal{S}} w_{n,i,t-1} P_{n,i,t} e_{i,t}. \quad (19)$$

2.4.3 Constraints

Flow conservation constraints. 预约需求从起点进入 SOC-wise expanded network，且服务量不超过实际预约需求：

$$\sum_{\{j|(o^p,j) \in \mathcal{A}^{n,p}\}} y_{A,o^p,j}^{n,p,t} \leq f_A^{n,p,t}, \quad \forall p \in \mathcal{P}, t \in \mathcal{T}, n \in \mathcal{N}, \quad (20a)$$

$$\sum_{\{j|(i,j) \in \mathcal{A}^{n,p}\}} y_{A,i,j}^{n,p,t} = \sum_{\{j|(j,i) \in \mathcal{A}^{n,p}\}} y_{A,j,i}^{n,p,t}, \quad \forall p \in \mathcal{P}, t \in \mathcal{T}, i \in \mathcal{S}^p, n \in \mathcal{N}. \quad (20b)$$

由于高速公路路径具有方向性，网络 $\mathcal{G}^{n,p}$ 可按路径顺序构造为无回路网络；在该条件下，起点流量结合中间站点流平衡即可保证被服务预约流最终到达终点。

Reservation service-level constraint. 为保证预约业务的服务质量，本文要求预测时域内预约用户服务率不低于给定阈值 η ：

$$S_A(y_A) \geq \eta D_A. \quad (21)$$

其中， $S_A(y_A)$ 和 D_A 分别由式(14) 和式(15) 定义。当 η 趋近于 1 时，模型更接近对预约用户的刚性服务保障；当 η 较低时，模型具有更大的经济优化自由度。由于跨越预测时域边界的预约指派已通过式(13) 的终端等效库存修正项承担未来库存影响，服务率约束仍可在完整预测决策集合 $\mathcal{T}$ 上计算，而无需人为剔除靠近预测域末端的预约需求。

Battery state transition constraints. 对于 SOC 状态 $r < N$ 的电池，时点 t 、站点 i 的库存由当前预测时域内到达并归还 SOC 为 r 电池的预约用户、预测时域开始前已经出发但在当前时域内到达的历史预约用户、当前随机用户归还的 SOC 为 r 电池，以及上一时点经过充电后转移到 SOC r 的站内电池构成：

$$\begin{aligned} w_{r,i,t} = & \sum_{p \in \mathcal{P}} \sum_{n \in \mathcal{N}} \sum_{\{j|(j,i) \in \mathcal{A}^{n,p}\}} \sum_{\{k \in \mathcal{T} | k + \tau_p, i = t\}} y_{A,j,i}^{n,p,k} \mathbb{I}(\rho_{j,i}^{n,p} = r) \\ & + \sum_{p \in \mathcal{P}} \sum_{n \in \mathcal{N}} \sum_{\{j|(j,i) \in \mathcal{A}^{n,p}\}} \sum_{\{k \in \{-\tau_{p,\max}, \dots, 0\} | k + \tau_p, i = t\}} \bar{y}_{A,j,i}^{n,p,k} \mathbb{I}(\rho_{j,i}^{n,p} = r) \\ & + y_R^{r,i,t}(y_A) + \sum_{m \in \mathcal{N}} w_{m,i,t-1} \chi_{m,i,t}^r, \\ & \forall i \in \mathcal{S}, r \in \mathcal{N} \setminus \{N\}, t \in \mathcal{T}. \end{aligned} \quad (22)$$

对于满电电池，时点 t 的库存等于上一时点经过充电达到满电的电池数量，减去当前时段被预约用户和随机用户换走的满电电池数量：

$$\begin{aligned} w_{N,i,t} = & \sum_{m \in \mathcal{N}} w_{m,i,t-1} \chi_{m,i,t}^N - Q_{i,t}^{A,\text{cur}} - Q_{i,t}^{A,\text{his}} - \sum_{n \in \mathcal{N}} y_R^{n,i,t}(y_A), \\ & \forall i \in \mathcal{S}, t \in \mathcal{T}. \end{aligned} \quad (23)$$

Swapping capacity constraints. 预约用户在时段 t 到达站点 i 的换电服务量不能超过可用满电电池数量：

$$Q_{i,t}^{A,\text{cur}} + Q_{i,t}^{A,\text{his}} \leq F_{i,t}, \quad \forall i \in \mathcal{S}, t \in \mathcal{T}. \quad (24)$$

该约束保证预约指派在实际到达换电时具有物理可行性。随机用户服务量随后由式(8)–(9) 根据剩余满电电池计算，其总量天然不超过随机需求和剩余满电电池数量，因此不再需要设置独立的随机用户服务上界约束。

Boundary and integrality constraints. 预测时域起点的电池 SOC 分布为已知初始状态：

$$w_{n,i,0} = \bar{w}_{n,i,0}, \quad \forall n \in \mathcal{N}, i \in \mathcal{S}. \quad (25)$$

所有预约服务量和电池库存变量均应满足非负性约束：

$$w_{n,i,t} \geq 0, \quad \forall n \in \mathcal{N}, i \in \mathcal{S}, t \in \mathcal{T}^w, \quad (26)$$

$$y_{A,i,j}^{n,p,t} \geq 0, \quad \forall p \in \mathcal{P}, n \in \mathcal{N}, t \in \mathcal{T}, (i,j) \in \mathcal{A}^{n,p}, \quad (27)$$

若需求量和电池数量均以整数计，则进一步有

$$w_{n,i,t} \in \mathbb{Z}_+, \quad y_{A,i,j}^{n,p,t} \in \mathbb{Z}_+. \quad (28)$$

引入 RL 终端价值后，MPC 不再仅依赖固定终端库存下界来处理末端效应。式(13)使用同一组库存边际价值 $\lambda_{i,n,\ell}$ 同时评估终端库存以及预测域外预约履约的终端等效库存修正，从而引导 MPC 在预测时域末端形成更合理的库存与预约承诺结构。与此同时，为保证运行安全，仍可保留如下终端满电电池库存下界作为可选硬约束：

$$w_{N,i,H} \geq \underline{w}_{N,i}, \quad \forall i \in \mathcal{S}. \quad (29)$$

其中， $\underline{w}_{N,i}$ 表示预测时域末端电站 i 至少需要保留的满电电池数量。在本文框架中，该约束主要作为安全库存下界，而长期影响的差异化评估由 RL critic 提供的终端库存价值项承担。

3 RL Formulation

RL 层用于学习充电功率控制策略，并通过 critic 为 MPC 提供终端库存价值信息。本节将充电功率控制问题建模为马尔可夫决策过程，并给出本文采用的 RL 算法。

3.1 Markov decision process

State. 在决策时刻 t ，RL agent 观测系统状态 s_t 。状态应包含影响当前充电功率决策及其长期后果的关键信息，主要包括各站点、各 SOC 状态的电池库存，未来预约需求，随机需求预测，未来电价，以及时间特征等：

$$s_t = \left(\{w_{n,i,t}\}_{i \in \mathcal{S}, n \in \mathcal{N}}, \{f_A^{n,p,\tau}\}_{\tau \in \mathcal{H}_t}, \{\hat{f}_R^{n,i,\tau}\}_{\tau \in \mathcal{H}_t}, \{e_{i,\tau}\}_{\tau \in \mathcal{H}_t}, \xi_t \right), \quad (30)$$

其中 $\mathcal{H}_t$ 表示 RL 可获得的预测信息窗口， ξ_t 表示时段、节假日或交通高峰等外生时间特征。已经形成但尚未到达的预约承诺在环境中作为未来履约需求处理，并在对应到达时刻转化为满电电池消耗和低 SOC 电池归还。状态中包含未来预测信息，是因为充电功率决策对后续满电电池供给、预约履约能力和充电成本具有跨时段影响。

Action. RL 的动作是充电功率决策。本文将动作表示为各站点、各 SOC 状态电池在当前时段采用的充电功率向量：

$$a_t = \{P_{n,i,t}\}_{i \in \mathcal{S}, n \in \mathcal{N}}. \quad (31)$$

动作需要满足功率上下界和充电资源限制。实际执行时，可将 actor 网络输出映射到可行功率区间，并通过投影或裁剪保证 $P_{n,i,t}$ 不超过站点充电能力和充电槽数量限制。该动作随后作为参数输入 MPC 层，用于计算充电成本和电池 SOC 状态转移。

Transition. 给定状态 s_t 和动作 a_t 后，系统首先以 $P_{n,i,t}$ 作为充电功率参数求解 MPC 用户服务分配模型，得到预约用户服务流量 y_A ；随机用户服务量随后由站点库存、预约用户实际到达服务量和随机需求实现值共同确定。其中，预测域内到达的预约换电事件进入库存转移；预测域外到达的预约履约事件则通过终端等效库存修正进入目标函数。随后，环境根据用户服务结果、随机需求实现值、电池充电过程以及预约承诺的滚动更新进入下一状态 s_{t+1} 。因此，状态转移可抽象表示为

$$s_{t+1} \sim \mathcal{P}(\cdot | s_t, a_t, \text{MPC}(s_t, a_t)), \quad (32)$$

其中 $\text{MPC}(s_t, a_t)$ 表示在当前状态和充电功率动作下求解得到的预约用户指派决策。滚动执行时，仅发布并实施当前通知窗口内的预约指派；随机用户服务量由实际到达时的剩余满电电池决定。已经实施且到达时刻位于未来的预约承诺会随时间前移，并在到达相应站点时进入库存消耗和归还电池更新。

Reward. RL reward 与系统运营目标保持一致，由实际执行时段内的服务收益、未满足预约需求惩罚和充电成本构成：

$$r_t = I_t - C_{1,t} - C_{2,t}. \quad (33)$$

其中 I_t 、 $C_{1,t}$ 和 $C_{2,t}$ 分别表示当前执行时段内实现的服务收益、未满足预约需求惩罚和充电成本。通过该 reward 设计，RL 层能够学习在不同需求、电价和库存状态下如何选择充电功率，以提高长期累计运营收益。

3.2 RL algorithm

由于充电功率是连续动作，且需要在不确定需求环境下保持训练稳定性，本文采用 Proximal Policy Optimization (PPO) 作为 RL 层的训练算法。PPO 属于 actor-critic 方法，actor $\pi_\phi(a_t | s_t)$ 输出连续充电功率动作的随机策略，critic $V_\theta(s_t)$ 估计当前状态的长期价值。选择 PPO 的一个重要原因是其 critic 直接学习 state value function，便于后续通过式(12) 提取终端库存的边际价值并传递给 MPC。

PPO 的 critic 通过最小化价值函数误差进行训练：

$$L_V(\theta) = \mathbb{E}_t \left[\left(V_\theta(s_t) - \hat{G}_t \right)^2 \right], \quad (34)$$

其中 $\hat{G}_t$ 为由采样轨迹计算得到的折扣回报或 bootstrap return。actor 则采用 clipped surrogate objective 更新策略。定义重要性采样比率

$$\rho_t(\phi) = \frac{\pi_\phi(a_t | s_t)}{\pi_{\phi_{old}}(a_t | s_t)}, \quad (35)$$

则策略优化目标为

$$L_{\text{CLIP}}(\phi) = \mathbb{E}_t \left[\min \left(\rho_t(\phi) \hat{A}_t, \text{clip}(\rho_t(\phi), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right], \quad (36)$$

其中 $\hat{A}_t$ 为优势函数估计， ϵ 为 clip 参数。优势函数可由广义优势估计（Generalized Advantage Estimation, GAE）计算：

$$\hat{A}_t = \sum_{l=0}^{\infty} (\gamma \zeta)^l \delta_{t+l}, \quad \delta_t = r_t + \gamma V_\theta(s_{t+1}) - V_\theta(s_t), \quad (37)$$

其中 ζ 为 GAE 参数。

训练完成后，actor 用于在每个决策时刻输出充电功率动作；critic 则用于提供 MPC 终端价值信息。具体而言，在每轮 MPC 求解前，系统构造参考终端状态 $\bar{s}_{\ell+H}$ ，并通过自动微分计算 $V_\theta(s)$ 关于终端库存 $w_{n,i,H}$ 的梯度，得到 $\lambda_{i,n,\ell}$ 。这些库存边际价值随后作为固定参数进入 MPC 目标函数中的线性终端价值项 Φ_ℓ^{RL} ；预测域外预约履约需求则被近似折算为终端等效库存修正，即用同一组 $\lambda_{i,n,\ell}$ 评价未来“— 满电电池需求 + 低 SOC 电池归还”的库存影响。由此，RL 层不仅提供充电功率控制动作，还将长期库存价值信息反馈给 MPC，形成闭环的 MPC-RL 协同优化机制。

4 Experiments

本节待补充。

5 Conclusion

本节待补充。